Topik : 4.4. Finalisasi Prototipe

Objective : Siapkan pipeline end-to-end: dataset \rightarrow FL \rightarrow DP \rightarrow hasil

Task : Uji ulang semua modul, pastikan reproducible



LOCAL (manual)

1. Dataset (Load Data)

2. Labeling

```
### 2 | Labeling rules

### 3 | Labeling rules

### 4 | Labeling rules

### 4
```

3. Preprocessing

4. Dataset per klien

5. Model

6. Federated learning

```
def clip_by_l2_norm(tensors, clip):
     cisp_o_s;
s = 0.8
for t in tensors: s += np.sum(np.square(t))
norm = float(np.sqrt(s)) + 1e-12
if norm <= clip: return tensors, 1.8
factor = clip / norm
return [t * factor for t in tensors], factor</pre>
def federated_train(noise_multiplier, rounds=5):
    DP_CLIENT_LR = 0.05
    DP_L2_MORN_CLIP_CLIENT = 1.5
    SERVER_CLIP = 5.0
    SERVER_LR = 1.0
      tf.keras.utils.set_random_seed(42)
np.random.seed(42)
      global_model = build_model(len(FEATURE_COLS))
global_model.compile(optimizer="sgd", loss="binary_crossentropy", metrics=["accuracy"])
global_weights = get_weights(global_model)
      for round_idx in range(1, rounds+1):
    client_ds = make_client_datasets(local_epochs=LOCAL_EPOCHS, shuffle=True)
    clipped_weighted_sums = None
    total_weight = 0.0
           for k, ds in enumerate(client_ds):

local_model = build_model(lentFEATURE_COLS))

set_weightr(local_model_global_weights)

opt = DPKerassGGODytimizer(

12_norm_clip=DP_12_MORM_CLIP_CLIENT,

noise_multiplier-noise_multiplier,

num_microbatches=BATCM_SIZE,

learning_rate-DP_CLIENT_LR,

momentum=0.9
                  w_local = local_model.get_weights()
delta = [wl - wg for wl, wg in zip(w_local, global_weights)]
delta_clipped, _ = clip_by_l2_norm(delta, SERVER_CLIP)
                    weight_k = float(client_sizes[k])
if clipped_weighted_sums is None:
    clipped_weighted_sums = [d * weight_k for d in delta_clipped]
                avg_delta = [cw / (total_weight+1e-12) for cw in clipped_weighted_sums]
avg_delta = [SERVER_IR * d for d in avg_delta]
global_weights = [cw + d for wg, d in zip(global_weights, avg_delta)]
set_weights(global_model, global_weights)
              gl_loss, gl_acc = evaluate_global(global_model)
acc_log.append(gl_acc)
loss_log.append(gl_loss)
print(f"[nm-{noise_multiplier:.3f}] Round (round_idx) | acc-(gl_acc:.4f) | loss-(gl_loss:.4f)*)
     except Exception:
eps = np.nan
```

7. Differential Privacy

8. Evaluasi

9. Plot Trade-off

Pipeline end-to-end:

1. Dataset (load data)

Tahap pertama Adalah mengambil data mentah dari tiga client:

- Dinsos → berisi informasi jumlah tanggungan, penghasilan, kondisi rumah
- Dukcapil → berisi informasi umur, status pekerjaan, status pernikahan
- Kemenkes → berisi informasi Riwayat penyakit, status gizi, tinggi, berat

Data ini di-*load* dari file CSV menggunakan pandas.read_csv(). Jika file tidak ada, program berhenti agar reproducibility terjaga.

2. Labeling

Data mentah tidak memiliki target langsung. Maka dibuat aturan untuk menentukan label layak_subsidi (1 = layak, 0 = tidak layak).

- Output tahap ini : kolom baru layak subsidi pada tiap dataset

3. Pre-processing

Agar model dapat dilatih:

- Numerik : nilai yang hilang diisi mendian, lalu di-*scale* pakai min-max normalisasi global
- Kategori : diubah menjadi one-hot encoding berdasarkan vocab gabungan (supaya konsisten antar klien)
- Fitur Tambahan : BMI dihitung dari tinggi & berat badan

Output: matriks fitur numerik dan vector label yang sudah bersih

4. Dataset per Klien

Setiap sumber data dianggap sebagai client dalam Federated Learning.

- Data tiap klien dikonversi ke tf.data.Dataset kemudian dilakukan batching, shuffling, repeat sesuai dengan local epochs
- Tiga dataset klien siap dipakai dalam loop training

Hal ini mensimulasikan kondisi nyata Dimana data tidak dikumpullkan disatu tempat, melainkan dilatih secara terdistribusi

5. Model

Menggunakan arsitektur:

- Input layer sesuai jumlah fitur
- Hidden layer : 64 neuron (ReLU) → 32 neuron (ReLU)
- Output layer: 1 neuron sigmoid (binary classification)

Penerapan model yang cukup ringan sehingga cocok untuk melakukan federated learning.

6. Federated Learning

Implementasi manual Federated Averaging (FedAvg):

- Tiap klien dimulai dari bobot global
- Klien melatih model local pada datasetnya dengan optimizer DP-SGD
- Delta bobot hasil training di-clip dengan L2 norm agar tidak terlalu besar

- Server melakukan aggregasi delta bobot dari semua klien (weighted average berdasarkan ukuran dataset
- Update bobot global → looping untuk beberapa round

7. Differential privacy

Untuk menjamin privasi data tiap klien, maka digunakan:

- DP-SGD Optimizer → menambahkan *noise Gaussian* ke gradien, plus clipping gradien
- Menggunakan parameter penting
 - o L2_norm_clip → batas clipping gradien
 - o Noise_multiplier → besar noise yang ditambahkan
- Estimasi privasi dihitung dengan menggunakan compute_dp_sgd_privacy → menghasilkan nilai ε (epsilon), semakin kecil artinya privasi lebih kuat

8. Evaluasi

Setelah setiap federated round:

- Model global dievaluasi pada gabungan semua data klien
- Metrics : accuracy dan loss
- Disimpan log per round agar bisa dianalisis konsistensinya
- Dicatat pula nilai rata rata akurasi/loss untuk tiap noise multiplier

9. Plot Trade-off

Hasil evaluasi divisualisasikan:

- Grafik Accuracy vs Epsilon (ε) → menunjukkan trade-off antara utility(akurasi)
 dan privacy (ε).
- Tiap titik diberi label nm = noise multiplier
- Grafik disimpan dalam file PNG agar reproducible

MENGGUNAKAN TFF

0. Load data

1. Aturan Labbeling

```
def label_dinsos(row):
    jt - row.get("jumlah_tanggungan", np.nan)
    ph - row.get("pumlah_tanggungan", np.nan)
    kr - row.get("sundisi_rumbi", ")
    if pd.isna(ph): ph - 0
    if pd.isna(ph): ph - 0
    if pt < 2 @@@ @@@ roturn ii
    if (kr in ("tidak layak", "semi permanen", "sangat sederhana")) and (ph < 5 @@@ @@@): return ii
    if (kr in ("tidak layak", "semi permanen", "sangat sederhana")) and (ph < 5 @@@ @@): return ii
    if ph >= 8 @@@ @@@: return @
    return ii
    if pa >= 8 @@ @@@: return @
    return ii
    if sp - row.get("status_pokerjaan", "")
    st - row.get("status_pokerjaan", "")
    if pd.isna(u): u = 0
    if u > 65: return ii
    if (sp-- virausaha") and (u>55): return ii
    if (sp-- virausaha"): return @
    return ii
    if (sp-- virausaha"): return @
    return ii
    if (seasenkos(row):
        rp - row.get("status_girif", ")
        sg - row.get("status_girif", ")
    if pd.notna(t) and pd.notna(b) and t > 0:
        bmi - b / ((t/i@e.) ** 2)
    if rp in ("kromis", "jantung", "giri burut"): return ii
    if (sm is not None) and (bmi < 17) or (tmi > 35)): return ii
    if (sm is not None) and (bmi < 18.5): return ii
    if (sm is not None) and (bmi < 17) or (tmi > 35)): return ii
    return ii
    if (sm is not None) and (bmi < 17) or (tmi > 35)): return ii
    return ii
    if (sm is not None) and (bmi < 18.5): return ii
    if (sm is not None) and (bmi < 18.5): return ii
    if (sm is not None) and (bmi < 18.5): return ii
    if (sm is not None) and (bmi < 18.5): return ii
    if (sm is not N
```

2. Pre-processing

3. Datasets

4. Model TFF

5. DP Aggregator

6. Training

7. Hasil

8. Plot

1. Load Dataset

- Membaca tiga dataset dari CSV (dinsos.csv, dukcapil.csv, kemenkes.csv).
- Fungsi load_or_fail dipakai agar jika file tidak ada, langsung error (FileNotFoundError).
- Dataset ini jadi sumber data mentah untuk setiap *client* federated learning.

2. Aturan Labeling

- Menentukan label target (layak_subsidi) berdasarkan logika aturan sosial/ekonomi/kesehatan.
- Ada tiga fungsi khusus:
 - o label dinsos: berdasar penghasilan, jumlah tanggungan, kondisi rumah.
 - o label dukcapil: berdasar umur, status pekerjaan, status pernikahan.
 - o label_kemenkes: berdasar riwayat penyakit, status gizi, serta perhitungan BMI.
- tiap dataset punya kolom biner layak subsidi (0 = tidak, 1 = ya).

3. Preprocessing (Encoding + Scaling)

- Menyatukan fitur numerik & kategorikal agar bisa dipakai model.
- Langkah:
 - Numerik: (jumlah_tanggungan, penghasilan, umur, tinggi_cm, berat_kg, BMI)
 → normalisasi dengan min-max global (pakai gabungan semua dataset supaya skala seragam).
 - 2. Kategorikal: (kondisi_rumah, status_pekerjaan, dll.) → di-*one-hot encoding* berdasarkan vocab global (union dari semua kategori di semua dataset).
- Output: X (fitur terstandarisasi) dan y (label biner).

4. Dataset Federated

- Ubah data tiap institusi jadi format tf.data.Dataset agar kompatibel dengan TFF.
- Fungsi to tf dataset \rightarrow menghasilkan dataset batched (X, y).
- Dikelompokkan sebagai *client*:
 - o Client 1: dinsos
 - o Client 2: dukcapil
 - o Client 3: kemenkes

5. Model TFF

- Definisi model ML yang akan dilatih secara federated.
- Model = Keras Sequential:
 - o Dense(64, relu)
 - o Dense(32, relu)
 - o Dense(1, sigmoid)
- Dibungkus dengan tff.learning.models.from_keras_model agar bisa dipakai di federated averaging.

6. Server-level DP Aggregator

- Menjamin privasi pada tahap agregasi model di server.
- Pakai GaussianSumQuery dari tensorflow-privacy → tambahkan *noise* Gaussian pada update agregasi.
- Dimasukkan ke TFF dengan DifferentiallyPrivateFactory.
- Hasilnya dipakai dalam tff.learning.algorithms.build unweighted fed avg.

7. Training Loop

- Melatih model federated dengan sampling client dan logging metrik.
- Tahapan tiap ronde:
 - 1. Pilih subset client (random sampling).
 - 2. Panggil learning process.next(state, sampled) untuk update global.
 - 3. Catat train accuracy dan loss tiap ronde.
- Bisa diulang dengan berbagai nilai noise multiplier (nm) untuk membandingkan trade-off.

8. Evaluasi & Plot

- Analisis hasil percobaan.
- Setelah training untuk semua nm selesai:
 - o Hitung rata-rata akurasi tiap noise multiplier.
 - o Plot kurva akurasi per ronde (dengan seaborn lineplot).

PERBANDINGAN MANUAL FEDERATED DAN TFF

1. Framework yang dipakai

- CODE 1
 - → Manual Federated Learning (pure NumPy + Keras), loop federasi dibuat manual, tidak pakai TFF.
 - → DP dilakukan di client-side dengan DPKerasSGDOptimizer (DP-SGD di level optimizer tiap klien).
- CODE 2
 - → TensorFlow Federated (TFF 0.87.0) dipakai untuk membangun algoritme federated (build_unweighted_fed_avg).
 - → DP dilakukan di server-side dengan

DifferentiallyPrivateFactory(GaussianSumQuery) (DP Aggregator).

2. Posisi Differential Privacy

- CODE 1 → Client-level DP-SGD
 - o Noise ditambahkan saat update gradien di setiap klien.
 - o Gunakan DPKerasSGDOptimizer, 12 norm clip, noise multiplier.
 - o Ada perhitungan epsilon dengan compute dp sgd privacy lib.
- CODE 2 → Server-level DP Aggregator
 - o Noise ditambahkan saat agregasi model update di server.
 - o Gunakan GaussianSumQuery + DifferentiallyPrivateFactory.
 - o Tidak ada perhitungan epsilon eksplisit, hanya log akurasi/loss.

3. Training Loop

- CODE 1 (manual)
 - o Loop round federasi ditulis sendiri (for round idx in range(rounds)).
 - o Model global diupdate manual (delta, clipping, averaging).
 - o Harus handle federated averaging secara eksplisit.
- CODE 2 (TFF)
 - Training loop lebih ringkas, karena learning_process =
 build_unweighted_fed_avg(...) sudah mengatur federated averaging.
 - Hanya perlu memanggil state, metrics = learning process.next(state, sampled).

4. Evaluasi Trade-off

• CODE 1

- ο Setelah training, dihitung ε (epsilon) via compute_dp_sgd_privacy_lib.
- o Plot: Accuracy vs Epsilon (langsung lihat trade-off privasi vs utilitas).

• CODE 2

- o Hanya menghitung rata-rata akurasi per noise multiplier.
- o Plot: Accuracy vs Round untuk tiap NoiseMultiplier.
- o Tidak ada epsilon.

5. Output

- CODE 1 menghasilkan:
 - o DataFrame dengan kolom: NoiseMultiplier, Accuracy, Loss, Epsilon.
 - Grafik: tradeoff fl accuracy epsilon.png (Accuracy vs Epsilon).
- CODE 2 menghasilkan:
 - o Rata-rata akurasi per NoiseMultiplier.
 - Grafik: *tff_serverdp_accuracy.png* (Accuracy vs Round, warna berdasarkan NoiseMultiplier).

Ringkasnya

- CODE 1 = manual FedAvg + DP-SGD di klien, ada perhitungan ε .
- CODE 2 = TFF FedAvg + DP Aggregator di server, hanya akurasi/loss.

TABEL PERBANDINGAN:

Aspek	Code 1	Code 2
Framework	Manual federated learning (NumPy +	TensorFlow Federated
	Keras)	
Posisi	Client-side DP-SGD → noise ditambahkan	Server-side DP Aggregator → noise ditambahkan
Differential	saat training klien	saat agregasi
Privacy		
DP Tools	DPKerasSGDOptimizer (optimizer dengan	GaussianSumQuery +
	clipping + noise) +	DifferentiallyPrivateFactory
	compute_dp_sgd_privacy_lib	
Clipping &	L2 clipping di level gradien tiap klien	L2 clipping di level update global sebelum
Noise		agregasi
Federated	Ditulis manual: delta weights dihitung &	Ditangani otomatis oleh
Averaging	dirata-rata sendiri	tff.learning.algorithms.build_unweighted_fed_avg
Training Loop	Manual loop, update global model	Gunakan learning_process.next(state, sampled)
	dilakukan sendiri	
Evaluasi	Hitung: Accuracy, Loss, dan ε (epsilon)	Hitung: Accuracy, Loss (tanpa epsilon)
Plot Trade-off	Accuracy vs Epsilon → menilai utility vs	Accuracy vs Round (per NoiseMultiplier)
	privacy	